



Universidad Nacional Autónoma de México

Facultad de Estudios Superiores Acatlán

Centro De Educación Continua

Proyecto Final Modulo V

Profesor: Fernando Barranco

Diplomado: Ciencia de Datos Grupo 34

2026 - Modulo V

Elaborado por:

Torres Ferrer Luis Noe



Índice

1. Introducción	4
2. Planteamiento del problema	4
2.1. Contexto	4
2.2. El problema	4
2.3. Pregunta de investigación	5
2.4. Objetivos	5
2.5. Nicho de negocio	6
2.6. Usuario final	6
2.7. Alcance	6
3. Descripción de los datos	6
3.1. Origen	6
3.1.1. Fuente A. Partidas y telemetría	7
3.1.2. Fuente B. Estadísticas de temporada	7
3.1.3. Fuente C. Repositorio de catálogos	7
3.2. Consideraciones de acceso	7
3.3. Estructura de la telemetría	8
3.4. Composición del corpus	8
4. Ingeniería de datos	9
4.1. Unidad de observación	9
4.2. Fase 1. Parseo y normalización	9
4.3. Fase 2. Agregación temporal	9
4.4. Fase 3. Variables derivadas	9
4.5. El reloj del juego: fase de la zona	10
4.6. Definición de la variable objetivo	10
4.7. Diccionario de variables	10
4.8. Prevención de fuga de información	11
5. Análisis exploratorio	11
5.1. Univariado	11
5.1.1. Calidad de los datos	12
5.1.2. Distribución de los predictores	12
5.1.3. Balance de la variable objetivo	12
5.1.4. Estructura temporal de la partida	14
5.2. Bivariado	14
5.2.1. Sesgo de supervivencia	14
5.2.2. Integridad del escuadrón y desenlace	14
5.2.3. Geografía y causa de las eliminaciones	15
5.2.4. Poder predictivo individual	16
5.3. Multivariado	17
5.3.1. Multicolinealidad	17



5.3.2. Componentes principales	17
5.4. Separabilidad a lo largo de la partida	18
5.5. Replanteamiento de la hipótesis inicial	18
5.6. Conclusiones de la etapa exploratoria	19
6. Modelación no supervisada	20
6.1. Características y prevención de fuga	20
6.2. Selección del algoritmo	20
6.3. Caracterización de los perfiles	21
6.3.1. Interpretación	21
6.4. Estabilidad	22
6.5. Aporte al modelo supervisado	22
7. Modelación supervisada	22
7.1. Metodología de evaluación	22
7.1.1. Partición por partida	22
7.1.2. Métricas	23
7.2. Resultados	23
7.2.1. Lectura de los resultados	23
7.3. Desempeño en función de la fase	24
7.4. Modelación secuencial	25
7.4.1. Recalibración	26
8. Estrategia de negocio	26
8.1. Accionables	26
8.2. Recorrido de un caso	26
8.3. Recorrido de un caso	27
8.4. Interfaz	27
8.4.1. El asistente conversacional	28
8.5. Despliegue	28
9. Conclusiones	29
9.1. Limitaciones	29
9.2. Trabajo futuro	30

1 Introducción

En los deportes profesionales existe desde hace décadas una métrica que estima, en cualquier instante de un encuentro, la probabilidad de que cada contendiente resulte vencedor. Esa cifra organiza la narración televisiva, orienta las decisiones de los cuerpos técnicos y permite al aficionado interpretar lo que observa. En los videojuegos competitivos, pese a que cada partida genera un registro digital exhaustivo de todo cuanto ocurre, esa métrica no existe de manera pública.

Este documento desarrolla dicha métrica para *PlayerUnknown's Battlegrounds*, videojuego del género *battle royale* en el que cien jugadores compiten sobre un mismo mapa mientras la zona habitable se reduce. A partir de la interfaz de programación oficial del estudio desarrollador se obtiene la telemetría completa de 150 partidas —más de un millón de registros de posición— y sobre ella se entrena un modelo que estima la probabilidad de que un escuadrón concluya en el cuarto superior de su partida.

El análisis exploratorio corrigió la hipótesis de partida. Se esperaba que el posicionamiento respecto de la zona segura fuera determinante; los datos muestran que el factor dominante es la integridad del escuadrón, y que cerca del 90 % de las eliminaciones proceden del combate directo frente a un 5 % atribuible a la zona. El planteamiento se reformuló en consecuencia.

El propósito no es sustituir el criterio del jugador sino asistirlo. Del mismo modo que un entrenador señala el momento en que una jugada se torció, el sistema identifica el minuto en que la partida dejó de ser ganable y explica qué condición la deterioró. La entrega final es una aplicación web donde el jugador introduce su nombre de usuario y recibe el análisis de sus partidas recientes, acompañado de un asistente conversacional que responde preguntas sobre su desempeño mediante texto o voz.

2 Planteamiento del problema

2.1 Contexto

El género *battle royale* congrega a decenas de millones de jugadores diarios. Su mecánica es sencilla de enunciar: los participantes aterrizan sobre un mapa extenso, recolectan equipamiento y se enfrentan mientras una zona segura se contrae de forma programada. Permanecer fuera de esa zona ocasiona daño continuo, de modo que la geografía impone un ritmo al que todos deben responder.

Detrás de esa aparente simplicidad hay un problema de decisión complejo. En cada instante el escuadrón resuelve un compromiso: avanzar hacia el centro de la zona reduce el riesgo geográfico pero aumenta la exposición al enemigo, mientras que permanecer en la periferia implica menos adversarios pero un margen de tiempo más estrecho. Esa tensión decide la mayoría de las partidas, y es justamente la que resulta invisible en las estadísticas disponibles.

2.2 El problema

Las plataformas de seguimiento estadístico existentes reportan agregados de resultado: eliminaciones acumuladas, daño infligido, cociente entre bajas y muertes, porcentaje de victorias.

Todas comparten una limitación de fondo: describen *qué* ocurrió, no *cuándo* ni *por qué*.

Un jugador que consulta su historial descubre que perdió, y acaso cuántas eliminaciones consiguió antes de hacerlo. Lo que no puede saber es en qué minuto la partida dejó de ser ganable ni qué decisión concreta produjo ese desenlace. La información necesaria para responderlo existe —el juego registra cada posición, cada disparo y cada contracción de la zona— pero permanece inaccesible, dispersa en archivos de bitácora que ninguna herramienta pública interpreta.

La consecuencia es que el jugador que desea mejorar carece de retroalimentación accionable. Puede repetir la observación de sus partidas grabadas, proceso que exige tanto tiempo como la partida original, o contratar entrenamiento personalizado, opción reservada al ámbito profesional. Entre ambos extremos no hay nada.

2.3 Pregunta de investigación

¿Es posible estimar, a partir de la telemetría disponible en un instante intermedio de la partida, la probabilidad de que un escuadrón alcance una posición determinada al final de la misma? Y en caso afirmativo, ¿a partir de qué momento esa estimación resulta suficientemente informativa para orientar una decisión?

La segunda parte importa tanto como la primera. Una estimación que solo se vuelve precisa cuando la partida está prácticamente resuelta carece de valor práctico, por elevada que sea su exactitud.

2.4 Objetivos

Objetivo general. Desarrollar un sistema que estime la probabilidad de supervivencia de un escuadrón en función del estado observable de la partida, y que entregue esa estimación al jugador de manera interpretable.

Objetivos específicos.

1. Construir un corpus de partidas a partir de la interfaz de programación oficial, con documentación completa de su procedencia.
2. Transformar la bitácora de eventos en una representación analítica cuya unidad de observación sea el escuadrón en un intervalo temporal.
3. Caracterizar la relación entre conducta espacial y desenlace mediante análisis exploratorio.
4. Comparar modelos de referencia con arquitecturas secuenciales, evaluando el desempeño en función del tiempo transcurrido.
5. Identificar perfiles de estilo de juego mediante técnicas no supervisadas.
6. Desplegar el sistema en una interfaz accesible al usuario final.

2.5 Nicho de negocio

La compañía ficticia **ZonaAzul** se sitúa en el sector de analítica aplicada a videojuegos competitivos, en un espacio intermedio entre dos categorías consolidadas. Por un lado, las plataformas de seguimiento estadístico ofrecen datos abundantes sin interpretación: presentan cifras que el jugador debe descifrar por su cuenta. Por otro, el entrenamiento profesional ofrece interpretación experta a un costo que lo restringe al alto rendimiento.

La propuesta de valor consiste en automatizar la parte interpretativa del entrenamiento: no mostrar más datos, sino señalar el momento decisivo y explicarlo en lenguaje natural.

2.6 Usuario final

Perfil	Necesidad	Cómo la atiende el sistema
Jugador intermedio (<i>principal</i>)	Comprender por qué pierde y qué corregir	Identificación del minuto crítico y del factor que deterioró su probabilidad
Escuadrón amateur	Evaluar decisiones colectivas de rotación	Comparación de la trayectoria del equipo frente a la de escuadrones exitosos
Creador de contenido	Sustentar el análisis con datos verificables	Curva de probabilidad exportable como material audiovisual

Cuadro 1: Usuarios objetivo y necesidades atendidas.

2.7 Alcance

El prototipo se acota a la plataforma Steam, la modalidad de escuadrón y el mapa Erangel, con un horizonte de análisis de quince minutos. Estas restricciones no responden a limitaciones técnicas sino a una decisión metodológica: reducir la variabilidad ajena al fenómeno estudiado permite evaluar la propuesta sin confundir el efecto del modelo con el de las diferencias entre mapas o modalidades. La extensión a otras configuraciones requiere reentrenamiento, no rediseño.

3 Descripción de los datos

3.1 Origen

Los datos proceden en su totalidad de interfaces de programación públicas. Se descartó el uso de conjuntos preprocesados de repositorios de terceros conforme a los requisitos del diplomado, y no se recurrió a extracción automatizada de contenido web, innecesaria al existir una interfaz oficial documentada.

3.1 Fuente A. Partidas y telemetría

La *PUBG Developer API*, mantenida por el estudio desarrollador, expone la información de partidas mediante una interfaz conforme a la especificación JSON:API. El acceso requiere una clave gratuita obtenible en <https://developer.pubg.com>. Se consumen cuatro recursos:

Recurso	Contenido y uso
/samples	Muestra de identificadores de partidas recientes. Constituye la fuente del conjunto de entrenamiento sin necesidad de conocer jugadores de antemano.
/players	Partidas recientes asociadas a un nombre de usuario. Habilita la personalización del análisis en la interfaz final.
/matches/{id}	Metadatos, composición de escuadrones y posición final alcanzada. De aquí procede la variable objetivo.
Telemetría (CDN)	Bitácora completa de eventos de la partida, en formato JSON. Es la fuente de todos los predictores.

Cuadro 2: Recursos consumidos de la interfaz oficial.

3.1 Fuente B. Estadísticas de temporada

Los recursos `/players/{id}/seasons/{seasonId}` y `/leaderboards` describen el desempeño acumulado del jugador durante una temporada. Constituyen un producto de datos distinto del anterior: mientras la telemetría caracteriza la conducta *dentro* de una partida, estos recursos caracterizan el nivel sostenido del jugador. Se contemplaron como fuente complementaria, pero no se utilizan en esta versión: ningún resultado del trabajo depende de ellas. Combinarlas con la telemetría queda como trabajo futuro..

3.1 Fuente C. Repositorio de catálogos

El repositorio oficial `pubg/api-assets` contiene los diccionarios que traducen los identificadores internos del motor de juego a denominaciones legibles. Cumple la función de tabla de catálogo del proyecto. Aporta además, en la aplicación, la imagen oficial del mapa de Erangel sobre la que se dibuja el recorrido de cada escuadrón, usada bajo los términos de desarrollador de PUBG: licencia no comercial y crédito visible.

3.2 Consideraciones de acceso

La documentación establece un límite de diez peticiones por minuto para la clave estándar, verificable mediante las cabeceras `X-RateLimit-Remaining` y `X-RateLimit-Reset`. Los recursos de partida y la descarga de telemetría quedan exentos de dicho límite, circunstancia que hace viable la construcción de un corpus de centenares de partidas sin gestionar cuotas adicionales.

Dos restricciones condicionan el diseño de la ingesta. La primera es el volumen: cada archivo de telemetría ocupa entre diez y treinta megabytes sin comprimir, por lo que el procesamiento se realiza en flujo, conservando únicamente los eventos requeridos. La segunda es

la ventana de retención: las partidas dejan de estar disponibles transcurrido cierto plazo, de modo que el corpus se preserva localmente en formato columnar inmediatamente después de su descarga. Esta decisión garantiza además la reproducibilidad del análisis con independencia de la disponibilidad del servicio.

3.3 Estructura de la telemetría

La telemetría no es una tabla sino una bitácora cronológica de eventos heterogéneos. Un registro puede describir el desplazamiento de un jugador, el siguiente una eliminación, el siguiente una contracción de la zona segura. Cada tipo de evento posee su propio esquema anidado.

Esta característica determina la magnitud del trabajo de preparación descrito en el Capítulo 4: antes de cualquier análisis es necesario decidir cuál será la unidad de observación y reconstruirla a partir de eventos dispersos en la secuencia. De los aproximadamente cuarenta tipos de evento disponibles se retienen tres:

Evento	Información extraída
LogPlayerPosition	Coordenadas, salud y escuadrón de cada jugador, con periodicidad aproximada de diez segundos.
LogGameStatePeriodic	Centro y radio de la zona segura, escuadrones y jugadores restantes.
LogPlayerKillV2	Eliminaciones, con posición de la víctima, causa y distancia. Se admite también la variante LogPlayerKill, empleada en versiones anteriores del juego.

Cuadro 3: Eventos retenidos durante el parseo.

3.4 Composición del corpus

El corpus final consta de 150 partidas del mapa Erangel en modalidad de escuadrón, descargadas de la muestra pública de la interfaz oficial. De ellas se extraen 1 110 787 registros de posición, 22 581 estados de la zona segura, 14 074 eliminaciones y 14 128 participaciones individuales.

Tras la transformación descrita en el Capítulo 4 se obtienen 46 886 observaciones escuadrón-ventana correspondientes a 3 931 escuadrones distintos. Al descartar los registros con valores ausentes en las variables de zona, el conjunto empleado para el modelado queda en 46 817 observaciones y 3 862 escuadrones.

El número de escuadrones por partida no es constante: oscila entre 15 y 38, con mediana de 26. Esta variabilidad se debe a que en la modalidad de escuadrón numerosos jugadores ingresan solos o en pareja, formando equipos incompletos. Como se explica en la sección 4.6, obliga a normalizar la variable objetivo.

4 Ingeniería de datos

Trabajar con bitácoras de eventos exige herramientas adecuadas para las tareas de limpieza, transformación y construcción de variables. El desarrollo se realiza en Python, apoyándose principalmente en *pandas* y *numpy* para la manipulación tabular, *pyarrow* para el almacenamiento columnar y *scikit-learn* para las transformaciones estadísticas.

4.1 Unidad de observación

Se define la unidad de observación como el **escuadrón-ventana**: un escuadrón observado durante un intervalo de sesenta segundos. Esta elección determina todo lo que sigue, y responde a la naturaleza del problema: la pregunta que el sistema debe contestar es «¿cómo va este equipo en este momento?», no «¿cómo le fue a este jugador en esta partida?».

El horizonte se recorta a los primeros quince minutos por dos razones. La primera es de diseño: la utilidad del sistema reside en avisar mientras la partida puede corregirse, no en explicar un desenlace consumado. La segunda es estadística: más allá de ese punto quedan pocos equipos vivos y las ventanas tardías se vuelven escasas y poco representativas.

4.2 Fase 1. Parseo y normalización

Cada archivo de telemetría se recorre una sola vez, distribuyendo sus eventos en tres tablas planas según su tipo. Las coordenadas, expresadas originalmente en centímetros del motor de juego, se dividen entre la dimensión del mapa correspondiente para obtener valores en el intervalo unitario. Esta normalización permite comparar mapas de distinto tamaño sin reentrenar.

El resultado se almacena inmediatamente en formato columnar comprimido y el JSON original se descarta.

4.3 Fase 2. Agregación temporal

La construcción de la tabla analítica requiere dos operaciones. En primer lugar, una unión por proximidad temporal hacia atrás asocia a cada observación de posición el estado de la zona segura vigente en ese instante; esta operación es necesaria porque ambos flujos se registran con periodicidades distintas. En segundo lugar, los jugadores de un mismo escuadrón se agregan dentro de cada intervalo mediante estadísticos de resumen.

4.4 Fase 3. Variables derivadas

Sobre la tabla agregada se construyen las variables que capturan la dinámica del juego. La principal es la **distancia relativa**, definida como

$$d_{\text{rel}} = \frac{\|c_{\text{equipo}} - c_{\text{zona}}\|}{r_{\text{zona}}} \quad (1)$$

donde c_{equipo} es el centroide del escuadrón, c_{zona} el centro de la zona segura y r_{zona} su radio vigente. Normalizar por el radio produce una magnitud comparable entre fases: un valor inferior a la unidad indica permanencia dentro de la zona, y uno superior indica exposición al daño.

Se añaden el desplazamiento del centroide entre ventanas consecutivas, como aproximación a la conducta de rotación, y el tamaño real del escuadrón, que distingue a los equipos completos de los incompletos.

4.5 El reloj del juego: fase de la zona

El radio de la zona segura no decrece de forma continua. Su histograma exhibe picos aislados en torno a 0,71, 0,60, 0,51, 0,40, 0,23 y 0,14, que corresponden a las fases programadas de contracción. La curva promedio de contracción presenta además un perfil aserrado, artefacto de promediar partidas que entran en cada fase en momentos distintos del reloj.

La consecuencia metodológica es importante: **el minuto transcurrido no es comparable entre partidas**. Dos escuadrones observados en el minuto diez pueden encontrarse en situaciones incomparables, uno con el círculo aún abierto y otro ya encerrado. Se define por tanto una variable ordinal $\text{fase} \in \{1, \dots, 6\}$ obtenida discretizando el radio, y se emplea como eje temporal de todo el análisis posterior en lugar del minuto.

4.6 Definición de la variable objetivo

Puesto que el número de escuadrones por partida oscila entre 15 y 38, una etiqueta absoluta resultaría inconsistente: terminar entre los diez primeros de 26 escuadrones equivale al 38 % superior, mientras que hacerlo entre 46 equivale al 22 %. Un modelo entrenado sobre esa etiqueta aprendería, en parte, el tamaño de la partida.

La variable objetivo se define en consecuencia sobre la posición relativa:

$$\text{pct_rank} = \frac{\text{posición final} - 1}{\text{escuadrones totales} - 1}, \quad \text{top25} = \mathbb{I}[\text{pct_rank} \leq 0,25] \quad (2)$$

La proporción resultante de escuadrones positivos es de 26.0 %, frente al 3.8 % que alcanzan la victoria absoluta. Conviene distinguir esta cifra de la proporción medida sobre observaciones, que asciende a 32.7 %: los escuadrones que sobreviven más tiempo generan más ventanas y quedan sobrerrepresentados en cualquier promedio directo sobre la tabla. Se prefiere la primera por razones de balance: con una tasa base cercana a cuatro por ciento el aprendizaje resulta inestable.

4.7 Diccionario de variables

Variable	Tipo	Descripción	Rango
ventana	ordinal	Minuto de juego transcurrido	0–14
fase_zona	ordinal	Fase de contracción del círculo	1–6
jugadores_vivos	discreta	Miembros del escuadrón con vida	1–5

Variable	Tipo	Descripción	Rango
tam_real	discreta	Tamaño inicial del escuadrón	1–5
hp_medio	continua	Salud promedio del escuadrón	0–100
hp_minimo	continua	Salud del miembro más comprometido	0–100
dist_centro	continua	Distancia normalizada al centro de la zona	0–0.69
dist_rel	continua	Distancia anterior entre el radio vigente	0–8.6
frac_fuera	continua	Proporción de observaciones fuera de la zona	0–1
radio_zona	continua	Radio normalizado de la zona segura	0.08–0.71
equipos_vivos	discreta	Escuadrones restantes en la partida	3–46
desplazamiento	continua	Movimiento del centroide entre ventanas	0–0.87
n_rosters	discreta	Escuadrones que iniciaron la partida	15–46
team_rank	discreta	Posición final alcanzada	1–46
pct_rank	continua	Posición final normalizada	0–1
top25	binaria	Objetivo: cuarto superior de la partida	0/1
top1	binaria	Objetivo secundario: victoria	0/1

Cuadro 4: Variables de la tabla analítica.

4.8 Prevención de fuga de información

Los metadatos de partida incluyen atributos que solo se conocen una vez concluida: tiempo de supervivencia, eliminaciones totales, daño infligido y distancia recorrida. Su incorporación como predictores generaría un desempeño aparente muy elevado y un modelo carente de utilidad, dado que en el instante de la predicción esa información no existe todavía.

Dichos atributos se excluyen del conjunto de predictores. Su empleo queda restringido al perfilamiento no supervisado del Capítulo 6, donde caracterizar la partida completa constituye el objeto mismo del análisis.

Por la misma razón, la partición entre entrenamiento y prueba se realiza por fecha de partida y no de manera aleatoria: las ventanas pertenecientes a una misma partida están correlacionadas entre sí, y repartirlas entre ambos conjuntos produciría una estimación optimista del desempeño.

5 Análisis exploratorio

El análisis exploratorio persigue tres finalidades: verificar la calidad e integridad del corpus, establecer si existe asociación entre la conducta observable y el desenlace, y caracterizar la estructura de dependencia entre predictores con vistas a la etapa de modelado. Se organiza en los tres enfoques habituales: univariado, bivariado y multivariado.

5.1 Univariado

5.1 Calidad de los datos

El corpus presenta una proporción muy baja de valores ausentes. La tabla siguiente los resume.

Variable	Ausentes	%	Origen
dist_centro, dist_rel, radio_zona, equipos_vivos, fase_zona	69	0.15	Posiciones anteriores al primer estado de juego registrado

Cuadro 5: Valores ausentes en la tabla analítica.

El caso de desplazamiento no constituye una deficiencia del registro sino una consecuencia de la definición de la variable, que se calcula como diferencia respecto de la ventana previa. Se imputa con valor cero: en su primer intervalo el escuadrón no se ha desplazado aún. Los restantes, por su magnitud marginal, se eliminan por listas.

La integridad de las etiquetas se verificó comprobando que cada partida presentara exactamente un escuadrón ganador. La condición se cumple en las **150 de 150 partidas**, y las posiciones finales forman secuencias completas en el rango de 1 a 38 sin omisiones.

Una comprobación adicional confirma el origen estructural de los valores ausentes en desplazamiento: su número, 3931, coincide exactamente con el de escuadrones del corpus, es decir, uno por cada primera ventana.

5.1 Distribución de los predictores

Tres rasgos merecen comentario. La salud promedio se concentra en el extremo superior, con más de la mitad de las observaciones por encima de 98 puntos: los escuadrones pasan la mayor parte del tiempo intactos, y el deterioro es un evento comparativamente raro pero informativo. La distancia relativa presenta una cola derecha muy larga, con valores de hasta 8.6 que corresponden a escuadrones muy alejados durante fases de círculo pequeño. Y el radio de la zona exhibe la estructura de picos discretos ya descrita, que motivó la construcción de la variable de fase.

5.1 Balance de la variable objetivo

La proporción de escuadrones que alcanzan el cuarto superior es de **26.0 %**, y la de escuadrones que ganan la partida de **3.8 %**.

Este desbalance condiciona la evaluación posterior. Un clasificador que prediga siempre la clase mayoritaria alcanzaría una exactitud del 96 % sobre la victoria absoluta sin haber aprendido nada. Por ello el análisis se apoya en el área bajo la curva ROC y en el puntaje de Brier.




Figura 1: Distribución univariada de los nueve predictores




Figura 2: Curva de supervivencia y contracción de la zona segura

5.1 Estructura temporal de la partida

Ambas curvas describen el mecanismo que estructura el juego. La eliminación de escuadrones sigue un descenso aproximadamente lineal, de 26 equipos iniciales a 13 en el minuto quince. La contracción del área, en cambio, permanece constante durante los primeros cuatro minutos y medio —el círculo inicial cubre casi todo el mapa— y a partir de ahí desciende por escalones.

Esa asincronía es precisamente lo que el modelo debe capturar: la presión geográfica antecede a sus consecuencias. Y explica también por qué la fase resulta un eje más informativo que el minuto.

5.2 Bivariado

5.2 Sesgo de supervivencia

Antes de examinar cualquier asociación es necesario documentar una propiedad estructural del corpus. La tabla analítica contiene únicamente escuadrones vivos, puesto que los eliminados dejan de generar registros de posición. En consecuencia, la proporción de escuadrones destinados al cuarto superior crece de forma monótona conforme avanza la partida.

Fase de la zona	Observaciones	Tasa base de top25
1	25 037	0.274
2	3 851	0.320
3	3 012	0.334
4	2 840	0.356
5	7 223	0.406
6	4 854	0.473

Cuadro 6: Proporción de escuadrones destinados al cuarto superior entre los que siguen con vida en cada fase.

La tasa base pasa de 0.274 en la primera fase a 0.473 en la última: se aproxima a duplicarse.

La tasa base casi se duplica entre la primera fase y la última. Esto no es un defecto del muestreo sino la naturaleza del fenómeno, y obliga a reformular la pregunta que el sistema responde. No es «¿va a ganar este escuadrón?» sino «**dado que este escuadrón sigue vivo en la fase t , ¿va a llegar al cuarto superior?**». Para una herramienta de entrenamiento esa es, además, la pregunta útil.

La implicación práctica para la evaluación es que el desempeño del modelo debe medirse *dentro* de cada fase. Comparar métricas entre fases sin controlar la tasa base conduciría a conclusiones erróneas.

5.2 Integridad del escuadrón y desenlace

La salud promedio del escuadrón separa con claridad ambos grupos, y lo hace desde la primera fase. Los escuadrones que terminan en el cuarto superior mantienen una salud promedio




Figura 3: Salud promedio según desenlace, por fase de la zona

alta y estable a lo largo de toda la partida, mientras que los restantes caen de forma pronunciada a partir de la segunda o tercera fase.

El mapa de correlaciones por fase confirma el patrón. La salud promedio correlaciona negativamente con la posición relativa —recuérdese que un valor bajo de `pct_rank` indica mejor desempeño— con coeficientes que alcanzan $-0,45$ en las fases intermedias, con diferencia el valor más alto del conjunto.

5.2 Geografía y causa de las eliminaciones




Figura 4: Densidad de eliminaciones sobre el mapa y causa de la baja

La distribución espacial de las eliminaciones muestra concentraciones marcadas en la zona central del mapa, coherentes con los núcleos urbanos de Erangel. La distribución de causas resulta más reveladora:

Causa de la eliminación	Proporción
Arma de fuego	≈ 60 %
Remate tras derribo	≈ 29 %
Zona de gas	≈ 5 %
Explosivos y otras causas	resto

Cuadro 7: Distribución de las causas de eliminación en el corpus.

Cerca del 90 % de las eliminaciones proceden del combate directo, frente a alrededor de un 5 % atribuible a la zona de gas. Este resultado tiene consecuencias directas sobre la interpretación del modelo y se retoma en la sección 5.4.

5.2 Poder predictivo individual




Figura 5: Información mutua y área bajo la curva univariada en la fase 3

Evaluados de forma aislada en una fase intermedia, los predictores se ordenan así: La salud promedio del escuadrón encabeza el ordenamiento con un área bajo la curva cercana a 0,65, seguida del número de integrantes con vida en torno a 0,60. Ninguna variable aislada supera ese nivel, lo que era esperable: el fenómeno es multivariado y ningún indicador individual resume el estado competitivo de un escuadrón. El orden, sin embargo, es informativo. Las tres primeras posiciones las ocupan variables que describen la *condición* del escuadrón, no su ubicación.

5.3 Multivariado

5.3 Multicolinealidad




Figura 6: Matriz de correlaciones y factores de inflación de varianza

Ningún predictor supera el umbral convencional de diez en el factor de inflación de varianza, próximo a 7, seguido de radio_zona en torno a 5.5. El resto se sitúa por debajo de 4.

El caso de dist_rel era previsible, puesto que se construye a partir de dist_centro y radio_zona, ambas presentes en el conjunto. Las correlaciones más altas son las de radio_zona con equipos_vivos (0,81) y dist_rel con frac_fuera (0,79), ambas explicables por construcción: las primeras son función del avance de la partida y las segundas comparten definición. La conclusión es favorable: no es necesario descartar variables por redundancia, de modo que los modelos lineales pueden emplear el conjunto completo sin comprometer la interpretación de sus coeficientes.

5.3 Componentes principales




Figura 7: Varianza explicada y proyección sobre los dos primeros componentes

Se requieren **cinco de los nueve componentes** para explicar el 90 % de la varianza. La ausencia de un salto pronunciado indica que la información del conjunto se reparte de forma relativamente uniforme y que la reducción de dimensionalidad ofrece poco margen.

La proyección sobre los dos primeros componentes no exhibe separación visual entre clases. Este resultado, lejos de invalidar el análisis, anticipa una propiedad del problema: la frontera de decisión no es lineal en el espacio original, lo que justifica el recurso posterior a modelos de ensamble y redes neuronales.

5.4 Separabilidad a lo largo de la partida




Figura 8: Área bajo la curva por fase de la zona, comparando predictores

El indicador central del proyecto no es un valor único sino una curva: la cantidad de información sobre el desenlace disponible en cada fase. Medida sobre el mejor predictor individual, presenta un comportamiento monótono creciente:

Las dos trayectorias divergen y esa divergencia es el hallazgo central del análisis exploratorio. La integridad del escuadrón gana poder predictivo de forma sostenida a lo largo de las seis fases. El posicionamiento relativo, en cambio, describe una parábola: alcanza su máximo en las fases intermedias y se degrada hasta el azar puro en la fase final, donde su área bajo la curva se aproxima a 0,50.

La interpretación es directa. En las fases intermedias, cuando el círculo se ha reducido pero aún permite maniobrar, la posición discrimina. En la fase final el área es tan pequeña que todos los supervivientes están forzosamente cerca del centro: la variable pierde varianza y con ella su capacidad discriminante.

5.5 Replanteamiento de la hipótesis inicial

El proyecto partió de una hipótesis explícita: que el posicionamiento relativo a la zona segura sería el principal determinante del desenlace. La intuición era razonable —permanecer fuera del círculo ocasiona daño continuo— y motivó la construcción de `dist_rel` como pieza central de la ingeniería de características.

El análisis exploratorio la corrige en dos sentidos.

La variable requiere control por fase. Considerada de forma agregada, `dist_rel` crece de forma sostenida entre la primera fase y la sexta, simplemente porque a menor radio corresponde mayor distancia relativa para una misma separación absoluta. Dado que solo alcanzan las fases avanzadas los escuadrones que sobrevivieron, la variable termina midiendo cuán lejos llegó el equipo antes que cuán bien se posicionó. Es un caso de confusión estadística que invierte el signo de la asociación aparente. Al controlar por fase, la asociación recupera el sentido esperado.

Su efecto es acotado y transitorio. Aun controlando por fase, `dist_rel` solo resulta competitiva en el tramo medio de la partida, y nunca supera a la salud del escuadrón.

Por qué falla la intuición. La distribución de causas de eliminación lo aclara: la zona de gas produce alrededor del 5 % de las bajas, mientras que cerca del 90 % procede del combate directo. En una partida de esta duración no mata el círculo, matan los adversarios. El posicionamiento importa como *mediador* —determina con quién te encuentras y en qué condiciones— pero no como causa directa del desenlace.

Reformulación. El planteamiento se ajusta en consecuencia:

Estimación del estado competitivo de un escuadrón a partir de su integridad y condición, condicionada a la fase de la partida.

`dist_rel` se conserva entre los predictores por dos motivos. Primero, porque su interacción con la salud puede resultar informativa aunque su efecto aislado sea modesto: un escuadrón herido y fuera de la zona no se encuentra en la misma situación que uno herido y protegido, y los modelos de ensamble y las redes neuronales pueden capturar esa interacción. Segundo, porque documentar una variable que la teoría sugería y los datos matizan forma parte del resultado.

5.6 Conclusiones de la etapa exploratoria

1. El corpus es íntegro. Las 150 partidas presentan exactamente un escuadrón ganador y secuencias de posiciones completas. Los valores ausentes son marginales y de origen estructural.
2. La variable objetivo debe normalizarse por el número de escuadrones de cada partida, que oscila entre 15 y 38.
3. El eje temporal correcto es la fase de la zona, no el minuto transcurrido, porque cada partida entra en las fases en momentos distintos del reloj.
4. Existe un sesgo de supervivencia que casi duplica la tasa base entre la primera fase y la última. La evaluación debe realizarse dentro de cada fase.
5. La integridad del escuadrón es el predictor dominante y su poder crece de forma monótona con la fase. El posicionamiento relativo solo resulta informativo en el tramo medio.

6. No existe multicolinealidad problemática. El conjunto completo de predictores puede emplearse sin restricciones.
7. Ningún predictor individual supera un AUC de 0.64, y los dos primeros componentes principales no separan las clases. El problema es multivariado y no linealmente separable, lo que justifica el recurso a modelos de ensamble y arquitecturas profundas.

6 Modelación no supervisada

El perfilamiento describe cómo juega un escuadrón, con independencia de su desenlace. Su propósito es doble: aportar una variable adicional al modelo supervisado y, sobre todo, ofrecer al usuario final una descripción de su estilo que resulte interpretable.

6.1 Características y prevención de fuga

El agrupamiento se realiza sobre la conducta de **apertura**, definida como los primeros cinco minutos de partida. Esta restricción no es arbitraria: calcular el perfil con la partida completa introduciría fuga de información, puesto que incorporaría lo ocurrido después del instante en que el modelo supervisado lo consume.

Dos variables quedan deliberadamente fuera del conjunto de agrupamiento:

- `tam_real` domina la distancia euclidiana. Con la mayoría de escuadrones en cuatro integrantes y una minoría en uno, particiona el espacio antes que cualquier variable de conducta: el resultado agrupa por tamaño de equipo, no por estilo de juego. Una primera versión del análisis lo confirmó, produciendo dos grupos separados únicamente por esa variable y sin diferencia alguna de desenlace.
- `frac_fuera` carece de varianza en la apertura, dado que el círculo inicial cubre prácticamente todo el mapa y ningún escuadrón se encuentra fuera de la zona.

En su lugar se incorpora la *variabilidad* de la conducta y no solo su promedio, lo que distingue a un escuadrón de rotación constante de otro que alterna reposo y desplazamientos bruscos. Las cinco características finales son salud de apertura, distancia de apertura, movilidad, variabilidad de distancia y variabilidad de movimiento.

6.2 Selección del algoritmo

Se comparan los cuatro métodos del temario sobre el conjunto estandarizado: K -medias, agrupamiento jerárquico con enlace de Ward, mezclas gaussianas y DBSCAN. Los tres primeros reciben el número de grupos como parámetro; DBSCAN lo infiere del radio de vecindad, por lo que se explora ese radio en su lugar y se reporta únicamente cuando identifica al menos dos grupos, condición que exige el coeficiente de silueta.




Figura 9: Coeficiente de silueta por algoritmo y número de grupos

La configuración seleccionada es *K*-medias con cuatro grupos.

6.3 Caracterización de los perfiles

Un agrupamiento sin interpretación no constituye perfilamiento. La tabla siguiente presenta la desviación de cada grupo respecto del promedio general, expresada en desviaciones estándar, junto con la denominación derivada de ese perfil.

Grupo	Salud	Distancia	Movilidad	Var. dist.	Var. mov.
Periféricos	+0,31	+0,71	−0,60	−0,77	−0,63
Rotadores	+0,33	+0,54	+1,23	−0,05	+1,19
Centrales	+0,26	−0,95	−0,36	+0,73	−0,35
Castigados	−2,10	−0,24	−0,24	−0,07	−0,12

Cuadro 8: Perfil de cada grupo respecto del promedio general, en desviaciones estándar.

Perfil	n	Mediana	Descripción
Rotadores	1 002	0.403	Máxima movilidad y rotación constante; cubren mucho terreno desde el inicio
Periféricos	1 102	0.423	Caen lejos del centro y se mantienen en posición, con poco movimiento
Centrales	1 275	0.520	Caen cerca del centro del mapa y se desplazan poco, pero reaccionan al cierre
Castigados	483	0.885	Llegan a los primeros minutos con la salud muy deteriorada

Cuadro 9: Tamaño y desenlace de cada perfil. La mediana corresponde a la posición relativa final, donde 0 es la victoria y 1 el último lugar.

6.3 Interpretación

Tres de los cuatro grupos describen *decisiones* y uno describe una *condición*. La distinción es importante y se reporta explícitamente.

Los Rotadores y los Periféricos representan estrategias opuestas —desplazamiento constante frente a permanencia en posición— y obtienen resultados prácticamente equivalentes, con medianas de 0.403 y 0.423. Este es el hallazgo más interesante del agrupamiento: no existe una única forma correcta de abrir la partida.

Los Castigados, en cambio, no se distinguen por su conducta sino por su salud de apertura, con una desviación de $-2,10$, el valor más extremo del análisis. Llegar deteriorado a los primeros cinco minutos no constituye un estilo de juego sino el resultado de un enfrentamiento temprano adverso. Que este grupo obtenga el peor desenlace no es por tanto un hallazgo sustantivo, y se documenta con esa salvedad.

6.4 Estabilidad

Se evalúa mediante remuestreo: se extrae el ochenta por ciento de los escuadrones, se reagrupa y se compara la asignación resultante con la original mediante el índice Rand ajustado. El valor medio obtenido sobre veinte repeticiones es de **0.975**, lo que indica que los grupos no dependen de la muestra concreta.

6.5 Aporte al modelo supervisado

La pregunta se responde con una comparación controlada: el mismo modelo, sobre el mismo subconjunto de observaciones —únicamente las ventanas posteriores a la apertura—, con y sin la variable de perfil.

Esta referencia es indispensable. Al restringir el análisis a las ventanas tardías el problema cambia de dificultad, y una mejora aparente podría deberse al recorte y no a la variable añadida.

El resultado es que **el perfil no aporta señal incremental**: el área bajo la curva es de 0.7165 con la variable y 0.7162 sin ella. Se reporta como resultado negativo. El estilo de apertura, tal como aquí se mide, no contiene información que los predictores existentes no capturen ya.

7 Modelación supervisada

7.1 Metodología de evaluación

7.1 Partición por partida

Las ventanas de una misma partida están fuertemente correlacionadas: describen a los mismos escuadrones en instantes consecutivos. Repartirlas al azar situaría el minuto siete de una partida en entrenamiento y el minuto ocho en prueba, produciendo una estimación gravemente optimista.

La partición se realiza por tanto agrupando por partida: todas las ventanas de una partida caen del mismo lado. El diseño original contemplaba una partición cronológica, descartada porque el corpus procede del recurso `/samples`, que devuelve partidas de una ventana temporal estrecha sin dispersión suficiente de fechas.

7.1 Métricas

Se reportan el área bajo la curva ROC, que mide la capacidad de ordenamiento, y el puntaje de Brier, que mide si las probabilidades son creíbles. La distinción importa para esta aplicación: la cifra se muestra al usuario como probabilidad, de modo que un modelo bien ordenado pero mal calibrado resultaría engañoso.

El desbalance se atiende mediante ponderación de clases y no por remuestreo, para no alterar la distribución de la que dependen las probabilidades.

7.2 Resultados

Modelo	AUC	Brier	AP
Impulso gradiente	0.6980	0.1958	0.5194
Red densa	0.6933	0.1973	0.5087
Bosque aleatorio	0.6927	0.2143	0.5127
Red recurrente	0.6877	0.2373	0.5152
Red recurrente (recalibrada)	0.6877	0.1976	0.5152
Regresión logística	0.6772	0.2237	0.4958

Cuadro 10: Desempeño en el conjunto de prueba, evaluado una sola vez tras la selección en validación.




Figura 10: Curvas ROC y diagrama de calibración

7.2 Lectura de los resultados

El impulso gradiente encabeza las tres métricas, pero la observación relevante es otra: **los cinco modelos se sitúan entre 0.677 y 0.698**. Una distancia de dos centésimas entre la familia más simple y la más compleja sugiere que el problema se aproxima al techo de lo que estas once variables pueden explicar, y no que falte capacidad de ajuste.

Dos observaciones adicionales. La red densa iguala al bosque aleatorio, de modo que la arquitectura profunda no penaliza frente al ensamble. Y la red recurrente presenta el peor puntaje de Brier pese a un área bajo la curva competitiva: su ordenamiento es razonable pero sus probabilidades están menos ajustadas. Y la red recurrente presenta el peor puntaje de Brier pese a un área bajo la curva competitiva: su ordenamiento es razonable, pero sus

probabilidades están desplazadas. La causa se identifica y corrige en la sección de modelación secuencial.

7.3 Desempeño en función de la fase

Dado que la tasa base crece con la fase por efecto del sesgo de supervivencia, el desempeño se evalúa dentro de cada fase y se reporta junto a esa tasa.

Fase	n	Tasa base	AUC	Brier
1	3 600	0.273	0.637	0.208
2	575	0.313	0.671	0.224
3	442	0.326	0.731	0.209
4	418	0.344	0.730	0.211
5	1 040	0.401	0.750	0.207
6	681	0.471	0.759	0.214

Cuadro 11: Desempeño del modelo seleccionado dentro de cada fase del círculo.

El área bajo la curva crece de forma sostenida y monótona, de 0.637 en la primera fase a 0.759 en la sexta. Este aumento no es un artefacto del sesgo de supervivencia: el área bajo la curva es invariante a la proporción de positivos —un clasificador aleatorio obtiene 0.5 con cualquier tasa base—, de modo que su crecimiento refleja una mejora real en la capacidad de ordenar a los escuadrones. La métrica sensible a la tasa base es la precisión promedio, cuya referencia para un clasificador aleatorio es precisamente esa tasa.

El puntaje de Brier, en cambio, permanece estable entre 0.207 y 0.224 a lo largo de las seis fases. La calibración no se degrada conforme avanza la partida, lo que resulta deseable para una aplicación que muestra la cifra al usuario como probabilidad.




Figura 11: Importancia por permutación de los predictores

La importancia por permutación confirma el hallazgo del análisis exploratorio. Las primeras posiciones las ocupan `hp_medio`, `hp_minimo` y `jugadores_vivos`, todas ellas descriptoras de la condición del escuadrón. Las variables de posicionamiento aportan considerablemente menos.

7.4 Modelación secuencial

Los modelos anteriores observan una fotografía: el estado del escuadrón en una ventana. La red recurrente procesa la trayectoria completa hasta ese momento, y puede por tanto distinguir a un escuadrón que llega con setenta puntos de salud tras un descenso sostenido de otro que llega con los mismos setenta tras un único enfrentamiento.

La arquitectura devuelve una predicción en cada paso y no solo al final, lo que produce directamente la curva de probabilidad que consume la aplicación.




Figura 12: Área bajo la curva de la red recurrente por minuto de partida

Minuto	n	Tasa base	AUC	Brier
0	557	0.262	0.518	0.248
2	551	0.265	0.576	0.244
4	521	0.280	0.624	0.239
6	492	0.297	0.667	0.237
8	444	0.329	0.710	0.238
10	396	0.369	0.729	0.239
12	338	0.432	0.748	0.225
14	293	0.498	0.758	0.215

Cuadro 12: Desempeño de la red recurrente por minuto de partida. Se presentan los minutos pares; la progresión completa es monótona salvo una inflexión en el minuto 10.

El desempeño crece de forma prácticamente monótona, desde 0.518 en el minuto inicial —indistinguible del azar— hasta 0.758 en el minuto catorce. El puntaje de Brier mejora en paralelo, de 0.248 a 0.215.

Este comportamiento contrasta con el observado en el análisis exploratorio para predictores individuales, donde la capacidad discriminante se degradaba en las fases finales, y constituye la evidencia de que la secuencia contiene información que el estado instantáneo no captura.

La discrepancia entre este desempeño y el valor agregado de la tabla anterior es aparente: el agregado promedia los minutos tempranos, donde ningún modelo puede discriminar, con los tardíos, donde la red resulta superior.

7.4 Recalibración

La red se entrenó con pesos que compensan el desbalance de clases. La ponderación favorece el aprendizaje de la clase minoritaria, pero desplaza las probabilidades hacia arriba: en el minuto inicial, el puntaje de Brier de la red en validación era de 0.248, peor que el 0.193 de un predictor constante igual a la tasa base. El mismo patrón aparece en los modelos tabulares: la regresión logística y el bosque aleatorio, que emplean ponderación de clases, obtienen peor calibración que la red densa y el impulso gradiente, que no la usan.

Dado que la aplicación muestra estas cifras al jugador como probabilidades, se recalibraron mediante escalado de Platt ajustado sobre el conjunto de validación. La transformación es monótona creciente, por lo que conserva el orden de los escuadrones: el área bajo la curva permanece en 0.6877. El puntaje de Brier en el conjunto de prueba mejora de 0.2373 a 0.1976, al nivel de los mejores modelos tabulares.

La recalibración tuvo una consecuencia adicional: dos reglas del informe automático estaban formuladas sobre la escala inflada y se revisaron. El umbral para señalar a un escuadrón que nunca fue favorito pasó a 50 %, y se eliminó la regla que valoraba el arranque de la partida, porque en el minuto inicial el análisis discrimina prácticamente al azar.

La conclusión es relevante: la red recurrente nunca discriminó peor que los demás modelos; sus probabilidades estaban mal escaladas. Corregido eso, es competitiva en ambas métricas y es la única que entrega una estimación por minuto.

8 Estrategia de negocio

8.1 Accionables

El sistema produce cuatro recomendaciones concretas, todas derivadas directamente de los resultados del modelo y no de apreciaciones cualitativas:

1. **Prioridad de mejora.** La importancia por permutación establece el orden: la integridad del escuadrón pesa más que su posicionamiento. El sistema indica en qué aspecto concentrar la práctica.
2. **Momento crítico.** Se identifica el minuto de mayor caída de probabilidad y el cambio de estado que lo acompaña, de modo que el jugador sepa qué segmento de su partida revisar.
3. **Comparación con la referencia.** El estado del escuadrón en cada fase se contrasta con la mediana de quienes alcanzan el cuarto superior, expresada en los mismos términos: salud, integrantes en pie y distancia al círculo.
4. **Diagnóstico de estilo.** La asignación a un perfil permite contrastar la conducta habitual con la de perfiles asociados a mejores resultados, y reconocer que existen estrategias distintas igualmente válidas.

8.2 Recorrido de un caso

8.3 Recorrido de un caso

Para ilustrar el uso del sistema se recorre el análisis de una partida real, consultada en vivo en la aplicación desplegada a partir del nombre de usuario de un jugador.

Al introducir el nombre de usuario en el buscador, el servicio consulta la interfaz oficial, descarga la telemetría de la partida más reciente compatible y la procesa con el mismo procedimiento que el corpus. El análisis completo tarda cerca de un minuto.

En el caso analizado, el escuadrón terminó en la posición 11 de 18 y perdió a tres integrantes, en los minutos 4, 7 y 8. La curva de probabilidad refleja esas bajas, y el sistema señala como momento crítico el minuto de mayor descenso. El mapa reproduce el recorrido sobre Erangel, con el cierre de la zona y la posición de cada baja, sincronizado con la curva: al desplazar el cursor por un minuto, el mapa muestra dónde estaba el escuadrón y cómo era el círculo en ese instante.

La comparación contra la referencia contrasta su salud y sus integrantes en pie con la mediana de los equipos que alcanzan el cuarto superior en el mismo cierre. La recomendación principal se dirige a la integridad del escuadrón, coherente con el hallazgo de que es el factor de mayor peso.

Este mismo caso sirvió para verificar la consistencia del despliegue: el procesamiento en producción y el local coinciden en las bajas, en sus minutos y en el rango de coordenadas.

8.4 Interfaz

La aplicación se organiza en cuatro pestañas y un buscador en el encabezado:

Vista	Contenido
Resumen	Los hallazgos principales en tarjetas visuales: las causas de eliminación, lo que más pesa para llegar al top, los perfiles y cómo mejora el acierto con el avance de la partida
Partidas	Casos agrupados por la forma de su curva. Para cada uno: indicadores, curva minuto a minuto con el momento clave, comparación contra los equipos del top, escenarios «¿y si...?» e informe
Perfiles	Los cuatro estilos de juego, con su huella en radar y una comparación directa entre ellos
Metodología	Fuentes, modelos comparados, calibración y diagrama del flujo, para el lector técnico
Buscador	En el encabezado: descarga y analiza la partida más reciente de cualquier jugador, con su recorrido sobre el mapa de Erangel

Cuadro 13: Vistas de la aplicación.

Toda la interfaz habla en lenguaje de jugador: los términos técnicos solo aparecen en la pestaña de metodología. El detalle se presenta en tarjetas desplegadas, y cualquier análisis puede compartirse como imagen.




Figura 13: Vista de partida: curva de probabilidad con el momento clave.

8.4 El asistente conversacional

La aplicación incorpora un asistente que responde preguntas sobre la partida cargada. Su diseño atiende explícitamente el riesgo de que un modelo de lenguaje produzca afirmaciones no verificables, mediante tres capas:

1. **Herramientas acotadas.** El asistente dispone de cinco funciones de solo lectura sobre los datos de la partida y de ninguna más. La restricción es estructural: carece de medios para responder sobre otro dominio.
2. **Salidas estructuradas.** El informe se genera contra un esquema declarado, de modo que la interfaz consume campos tipados y no prosa libre.
3. **Validación posterior.** Antes de mostrarse, se comprueba que las cifras citadas existan en los datos entregados. Una respuesta que no supera la validación se descarta y se reintenta; si vuelve a fallar, el sistema reconoce que no puede responder con seguridad.

El sistema dispone además de un modo determinista, basado en reglas, que produce el mismo informe sin credenciales. Cumple una doble función: garantiza que la aplicación opere en ausencia del servicio externo y sirve de referencia contra la cual evaluar si el modelo de lenguaje aporta algo por encima de un conjunto de reglas.

8.5 Despliegue

La interfaz se publica como aplicación estática y el servicio de análisis como proceso independiente. El plan gratuito de la plataforma de despliegue impone un límite de 512 MB de memoria, restricción que determinó una decisión de ingeniería: el análisis en vivo emplea el modelo tabular y no el secuencial, puesto que la sola importación del entorno de aprendizaje

profundo agota la memoria disponible. Las partidas precalculadas conservan las predicciones del modelo secuencial. La aplicación está disponible en <https://dax-theta.vercel.app>, el servicio de análisis en <https://dax-li6v.onrender.com> y el código fuente en <https://github.com/luistfact/DAX>. El notebook es reproducible en Google Colab sin credenciales: descarga el corpus del repositorio y, si no puede, opera con datos simulados sin interrumpirse.

9 Conclusiones

El trabajo partió de una pregunta: si es posible estimar, a partir de la telemetría disponible en un instante intermedio de la partida, la probabilidad de que un escuadrón alcance una posición determinada. La respuesta es afirmativa, con matices que conviene precisar.

El desenlace es predecible por encima del azar. Los cinco modelos evaluados superan el 0.677 de área bajo la curva sobre un conjunto de prueba reservado, y el desempeño crece con el avance de la partida, desde 0.637 en la primera fase hasta superar el 0.73 en las intermedias.

La hipótesis inicial se corrigió con evidencia. El diseño asumía que el posicionamiento respecto de la zona segura sería determinante. Los datos lo desmienten: la distancia relativa apenas discrimina, y la explicación está en la propia distribución de eliminaciones, donde la zona de gas produce alrededor del cinco por ciento de las bajas frente a cerca del noventa por ciento atribuible al combate directo. El predictor dominante resultó ser la integridad del escuadrón. Esta corrección no es un contratiempo del análisis sino uno de sus resultados.

La secuencia aporta información que el estado instantáneo no contiene. La red recurrente, evaluada minuto a minuto, mejora de forma sostenida a lo largo de la partida, mientras que los predictores individuales pierden capacidad discriminante en las fases finales.

Existen estilos de juego diferenciados y estables. El agrupamiento identifica cuatro perfiles con un índice Rand ajustado de 0.975, y revela que dos estrategias opuestas —rotación constante y permanencia en la periferia— conducen a resultados equivalentes. El perfil, sin embargo, no aporta señal incremental al modelo supervisado, y así se reporta.

El problema tiene un techo aparente con estas variables. La estrechez entre familias de modelos sugiere que el margen de mejora no está en el ajuste sino en la información disponible.

9.1 Limitaciones

1. El corpus procede de una ventana temporal estrecha, por lo que no se evalúa la estabilidad del modelo frente a cambios de versión del juego.
2. El análisis se restringe a un mapa y una modalidad; la generalización requiere reentrenamiento.
3. El horizonte de quince minutos deja fuera la fase final de las partidas largas.
4. La recalibración se ajustó sobre el mismo corpus de ventana temporal estrecha; su vigencia frente a cambios de versión del juego no se evaluó.
5. El sistema opera sobre el conjunto de prueba del modelo y sobre partidas consultadas en vivo, pero no acumula historial por jugador.

9.2 Trabajo futuro

- **Equipamiento del escuadrón.** Es la línea más prometedora. La telemetría permite reconstruir el inventario mediante los eventos de recogida y descarte de objetos, así como el uso efectivo de curaciones. Un escuadrón sano pero mal armado no se encuentra en la misma situación que uno sano y bien equipado, y las variables actuales no distinguen ambos casos. Buena parte del techo observado podría residir ahí.
- **Calibración de la red recurrente** Comparar el escalado de Platt con la regresión isotónica como método de recalibración.
- **Representación espacial.** Rasterizar el estado de la partida como imagen multicanal permitiría emplear redes convolucionales y aprovechar la estructura geográfica que las variables agregadas resumen pero no representan.
- **Historial por jugador.** La interfaz oficial retiene las partidas durante un plazo limitado, de modo que construir un historial exige acumulación sostenida. Con él sería posible evaluar la evolución del desempeño de un mismo jugador a lo largo del tiempo.
- **Extensión a otros mapas y modalidades,** para evaluar la capacidad de generalización.

Referencias

- [1] Acosta González, O. D. (2026). *Introducción: Redes neuronales profundas y conceptos clave* [Diapositivas de PowerPoint]. Diplomado en Ciencia de Datos (Módulo IV), Facultad de Estudios Superiores Acatlán, Universidad Nacional Autónoma de México.
- [2] Acosta González, O. D. (2026). *Redes neuronales convolucionales: Tensores y Aplicaciones* [Diapositivas de PowerPoint]. Diplomado en Ciencia de Datos (Módulo IV), Facultad de Estudios Superiores Acatlán, Universidad Nacional Autónoma de México.
- [3] Acosta González, O. D. (2026). *Redes neuronales convolucionales: Dropout y Optimizadores* [Diapositivas de PowerPoint]. Diplomado en Ciencia de Datos (Módulo IV), Facultad de Estudios Superiores Acatlán, Universidad Nacional Autónoma de México.
- [4] Acosta González, O. D. (2026). *Modelado secuencial - RNN: LSTM vs GRU* [Diapositivas de PowerPoint]. Diplomado en Ciencia de Datos (Módulo IV), Facultad de Estudios Superiores Acatlán, Universidad Nacional Autónoma de México.